

Машинное обучение

Лекция 1

Тема: Введение в машинное обучение

1. Основные определения и постановки задачи

Машинное обучение — это наука, изучающая способы улучшения характеристик из ограниченного набора примеров. Есть еще много близких направлений, к анализу данных можно отнести любую работу, связанную с изучением информации из данных.

Объектом (X) мы будем называть то, для чего хотим сделать предсказание. Множество всех возможных точек различия называется пространством объектов и обозначается через X .

Варианта, которую мы хотим предсказать, называется ответом или целевой переменной, а множество ее значений — пространством ответов Y .

Типичный пример называется обучением с учителем, а все ее совокупность — обучением без учителя.

$$X = \{(x_1, y_1), \dots, (x_n, y_n)\}$$

где x_1, \dots, x_n — обучающиеся объекты, а y — их классы.

Объекты — это некие абстрактные сущности, которыми компьютеры не умеют оперировать напрямую.

Для дальнейшего анализа нам понадобится описать объекты с помощью некоторого характера, который позволяет описывать объекты. Вектор всех признаков объекта x называется признаковым описанием этого объекта.

На работе со множеством данных мы специализируемся активно развивающемся сейчас направлении обучения (deep learning).

Описывая задачу, являясь примером задачи обучения с учителем (supervised learning), а более конкретно задачу регрессии.

Варианты задачи с учителем:

1. $Y = \{0, 1\}$ — бинарное классификация
2. $Y = \{1, \dots, K\}$ — многоклассовая классификация
3. $Y = \{0, 1\}^d$ — многоклассовая классификация с перекрывающимися классами
4. Задача регрессии — задача, в которой для каждого объекта требуется определить не только ответ, а для других также предсказать.

Существует также обучение без учителя — классы задач, где ответы неизвестны или вообще не нужны, и требуется найти некоторые закономерности и зависимости между данными на основе предельной информации.

1. Кластеризация — задача разделения объектов на группы, обладающие некоторыми свойствами.

2. Описание плотности — задача приближенного распределения объектов.

3. Визуализация — задача изобразительного многомерных объектов в двумерном или трехмерном пространстве.

пространстве

4. Поиск похожих объектов — задача нахождения объектов, похожих на заданные, или наоборот, объектов, непохожих на заданные.

Бинарные постановки — обучение с подкреплением (reinforcement learning) где алгоритм на каждом шаге принимает решение по ситуации, выбирает одно из доступных ему действий, получает некоторую награду и корректирует свою стратегию.

Объекты — признаки

$$X \in R^{d \times n}$$

d — число объектов
 n — число признаков

Построение функции $a: X \rightarrow Y$, которая для любого объекта будет предсказывать ответ. Такая функция называется алгоритмом или моделью.

Если функционал устроен так, что возникает минимизация, то можно назвать его функционалом ошибки.

Крайне популярным функционалом в задаче регрессии является среднеквадратичная ошибка:

$$Q(a, X) = \frac{1}{2} \sum_{i=1}^n (a(x_i) - y_i)^2$$

Линейные модели

$$A = \{a(x) = w_0 + w_1 x_1 + \dots + w_d x_d \mid w_0, w_1, \dots, w_d \in R\}$$

MSE:

$$\frac{1}{2} \sum_{i=1}^n (w_0 + \sum_{j=1}^d w_j x_{ij} - y_i)^2 \rightarrow \min_{w_0, w_1, \dots, w_d}$$

Процесс поиска оптимального алгоритма называется обучением.

Важная характеристика семейства алгоритмов — чем меньше у нас данных для обучения, тем более простое семейство следует выбирать.

Этапы решения задачи машинного обучения:

1. Постановка задачи
2. Выбор признаков
3. Формирование выборки
4. Выбор функционала ошибки
5. Выбор метода решения
6. Построение модели
7. Проверка качества модели

Лекция 2

Тема: Линейная регрессия

1. Линейные модели

Модели сводятся к суммированию значений признаков с некоторыми весами:

$$a(x) = w_0 + \sum_{j=1}^d w_j x_j$$

Параметрами модели являются веса или коэффициенты w_j .

Вес w_0 также называется свободным членом или сдвигом (bias).

Линейная модель в более компактном виде:

$$a(x) = w_0 + \langle w, x \rangle$$
где $w = (w_0, \dots, w_d)$ - вектор весов.

Прямая часто используется для того, чтобы упростить задачу еще сильнее. Прямая n - это линейное описание некоторой области $(d+1)$ -й природы равности средине. Все при этом происходит как раз, чтобы иметь весовые коэффициенты, и поэтому в описании w_0 содержится:

$$a(x) = \langle w, x \rangle$$

② Область применимости линейной модели. Интерпретация признаков. Пусть мы имеем линейную модель $f(x)$ которая принимает значения y и имеет веса w_0, \dots, w_m . Значения w_0 на m признаков $x_1(x), \dots, x_m(x)$

$$f(x) = [f_0(x)] = c_0$$
 one-hot

Итак, что признаки $x_1(x), \dots, x_m(x)$ в a линейно независимы для линейной модели

$$f_1(x) + \dots + f_m(x) = 1$$

Если мы применим линейную модель к данным после one-hot кодирования признаков

$$a(x) = w_0 [f_0(x) = c_0] + \dots + w_m [f_m(x) = c_m] + [взвешенный] \text{ вес с другими признаками}$$

Работа с тестом.

Найдем все слова, которые есть в нашем наборе тестов и признаков $x = \{c_1, \dots, c_m\}$ будем считать тест x признаками $x_1(x), \dots, x_m(x)$ для $f(x)$ будем как-то выбирать слова c_i в тесте.

Линейная модель над такими признаками:

$$a(x) = w_0 f_0(x) + \dots + w_m f_m(x) + \dots$$

Бинаризация числовых признаков.

Чтобы линейная модель могла работать с числовыми признаками, для этого делаем их бинарными. Для этого берем интервалы между точками $\{x_1, \dots, x_m\}$. Это позволяет нам разбить интервал между минимальными и максимальными значениями на отрезки t_1, \dots, t_m .

Добавим еще точки $t_0 = -\infty$ и $t_{m+1} = +\infty$

$$f_i(x) = [t_i < x_i \leq t_{i+1}]$$

Линейная модель над этими признаками:

$$a(x) = w_0 [t_0 < x_1 \leq t_1] + \dots + w_m [t_m < x_m \leq t_{m+1}] + \dots$$

③ Измерение ошибки в задаче регрессии. MSE. Самый простой способ измерения ошибки - посчитать квадрат разности

$$L(y, a) = (a - y)^2$$

Связанный с ней функционал называется функционалом потерь (CO)

$$MSE(a, X) = \frac{1}{2} \sum_{i=1}^n (a(x_i) - y_i)^2$$

Квадрат CO можно интерпретировать как сумму квадратов ошибок. Так, если мы ищем в пространстве, то MSE будет измеряться в квадратах. Чтобы избежать этого используем корень CO.

$$RMSE(a, X) = \sqrt{\frac{1}{2} \sum_{i=1}^n (a(x_i) - y_i)^2}$$

Среднеквадратичная ошибка популярна для сравнения моделей. Она не позволяет сравнивать модели, но не позволяет сравнивать модели, насколько хорошо данная модель решает задачу.

В таких ситуациях вместо CO можно использовать функцию потерь.

$$R(a, X) = 1 - \frac{\sum_{i=1}^n (a(x_i) - y_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

где $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$ - среднее значение целевой переменной.

MAE. Заменит квадрат отклонения на модуль.

$$L(y, a) = |a - y|$$

Сумма-и-абсолютных называется суммой абсолютных отклонений MAE

$$MAE(a, X) = \frac{1}{n} \sum_{i=1}^n |a(x_i) - y_i|$$

Если мы хотим MSE в качестве функционала ошибки, то получаем среднее значение

$$\frac{1}{n} \sum_{i=1}^n (a - y_i)^2 \rightarrow \min_a$$

Найдем значения a на среднем значении всех ответов.

$$a_{MSE}^* = \frac{1}{n} \sum_{i=1}^n y_i$$

Функционал HAF:

$$\frac{1}{n} \sum_{i=1}^n |a - y_i| \rightarrow \min_a$$

Вернемся к ответам:

$$a_{MAE}^* = \text{median}\{y_i\}_{i=1}^n$$

Huber loss. Функция потерь Хьюбера:

$$L(y, a) = \begin{cases} \frac{1}{2} (y - a)^2, & |y - a| < \delta \\ \delta (|y - a| - \frac{\delta}{2}), & |y - a| \geq \delta \end{cases}$$

Log-Cosh. Функция потерь log-cosh

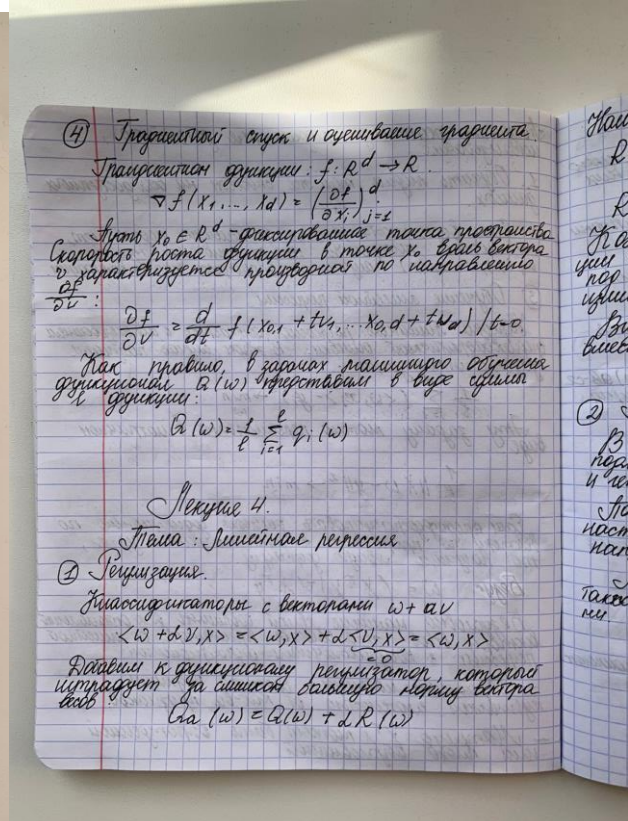
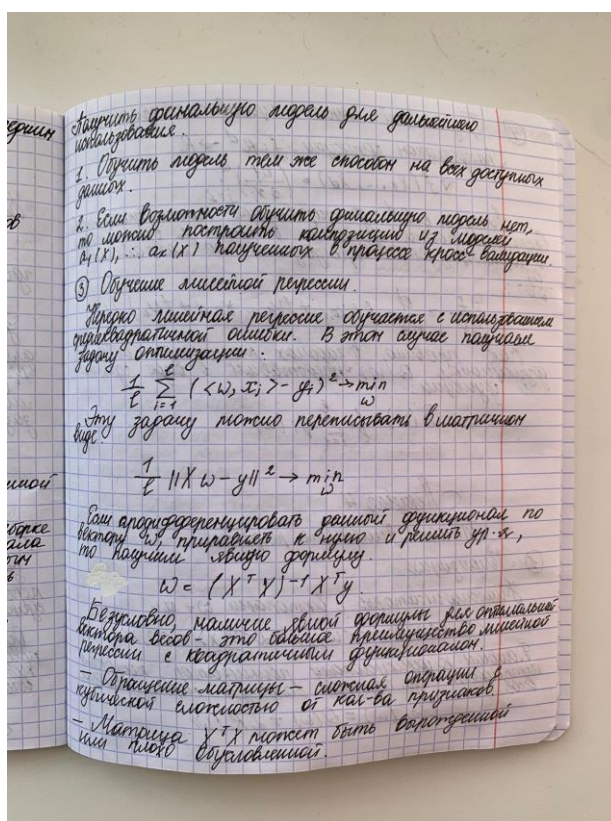
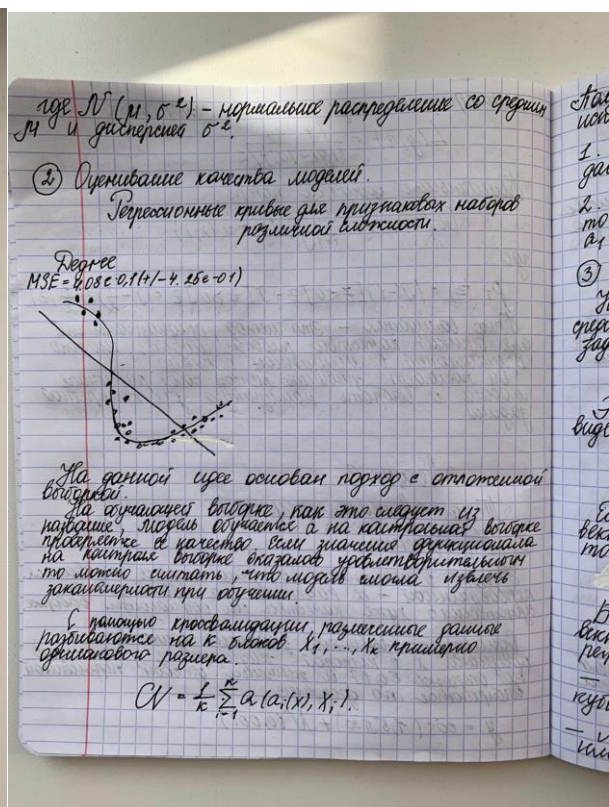
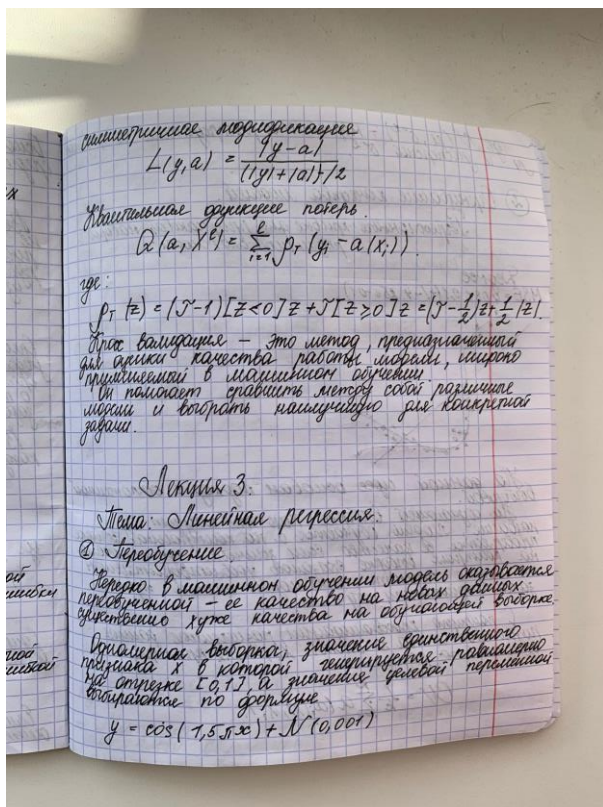
$$L(y, a) = \log \cosh(a - y)$$

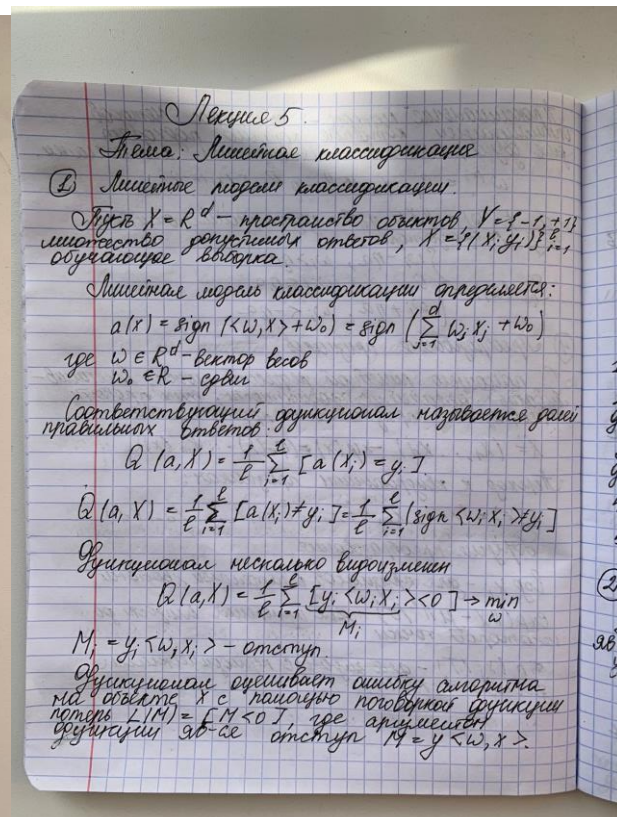
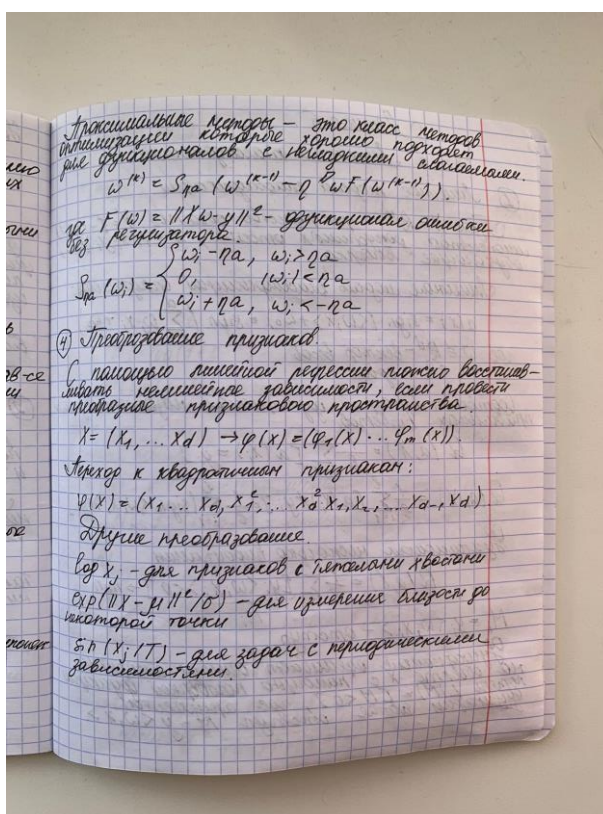
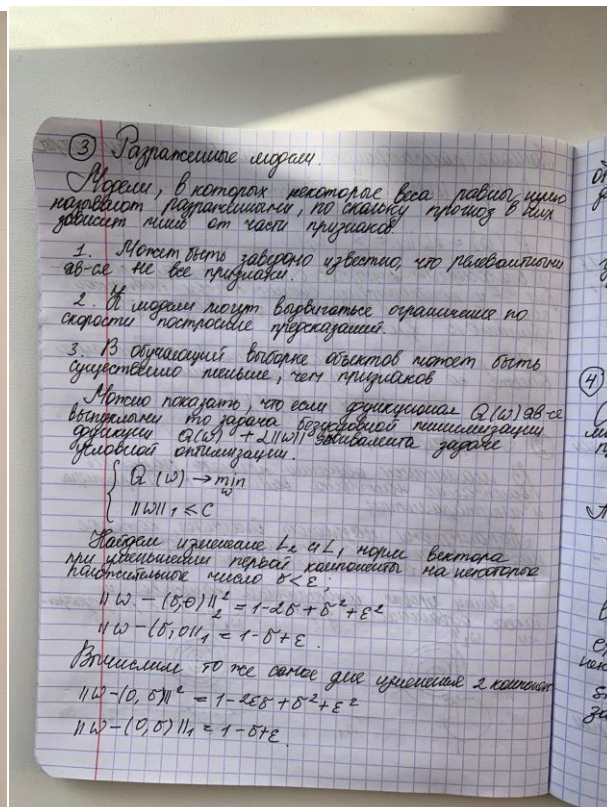
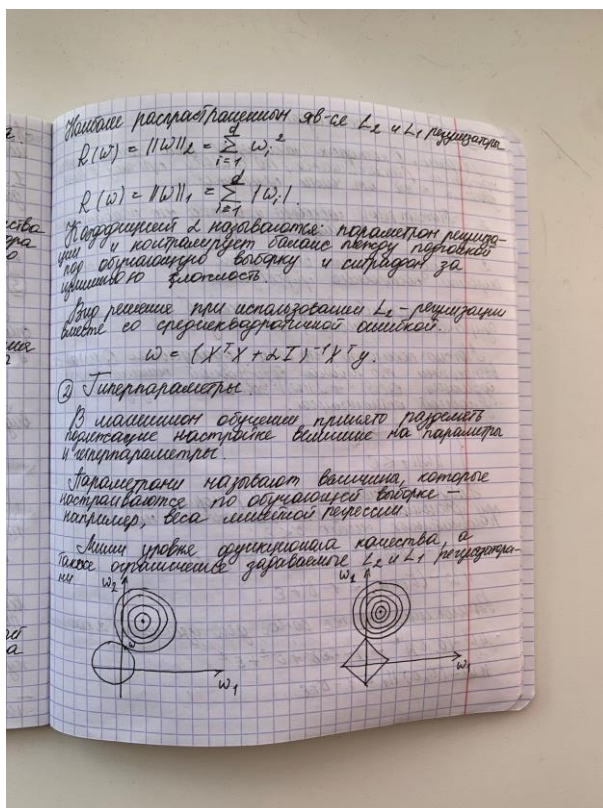
MSLE. Среднеквадратичная логарифмическая ошибка

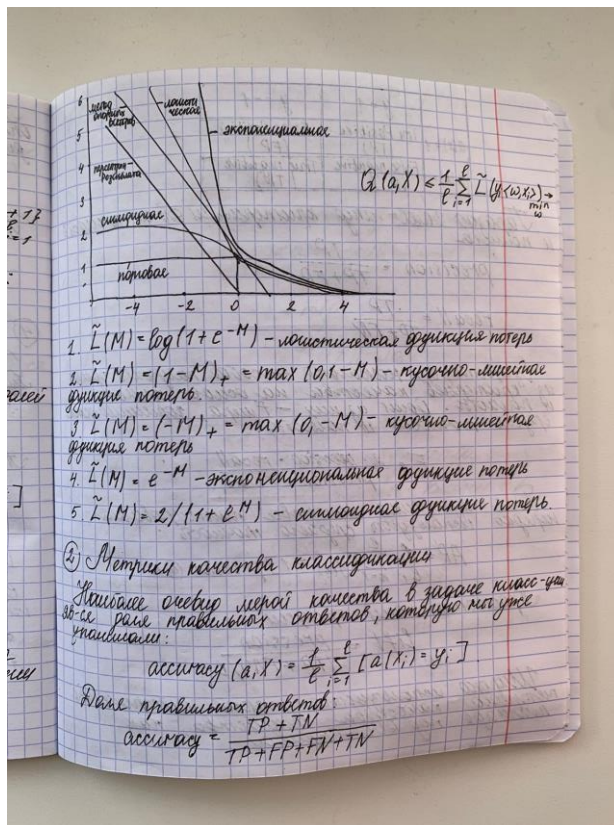
$$L(y, a) = (\log(a+1) - \log(y+1))^2$$

MAPE и SMAPE. Средний абсолютный процентный отклонения

$$L(y, a) = \left| \frac{a - y}{y} \right|$$







	$y = 1$	$y = -1$
$a(x) = 1$	True Positive (TP)	False Positive (FP)
$a(x) = -1$	False Negative (FN)	True Negative (TN)

Тогда более интуитивными будут точность и полнота:

$$precision = \frac{TP}{TP + FP}$$

$$recall = \frac{TP}{TP + FN}$$

Существует несколько способов получить один из критериев качества на основе точности и полноты. Один из них - F-мера, гармоническое среднее точности и полноты:

$$F = \frac{2 \cdot precision \cdot recall}{precision + recall}$$

Для измерения качества ранжирования широко используется среднее точности:

$$AP = \frac{1}{n} \sum_{k=1}^n [y_{(k)} = 1] precision @ k$$

Простота концентрации:

$$lift = \frac{precision}{(TP + FN) / n}$$

Широко используется также интерпретируемая метрика качества сортировки, как lift - кривая.

$$FPR = \frac{FP}{FP + TN} ; TPR = \frac{TP}{TP + FN}$$

Лекция 6

Тема: Линейная классификация

Линейный классификатор основан на минимизации функции потерь.

$$\frac{1}{n} \sum_{i=1}^n L(y_i, \langle w, x_i \rangle) \rightarrow \min_w$$

- $L(y, z) = \log(1 + \exp(-yz))$ - логарифмическая функция потерь
- $L(y, z) = (1 - yz)_+$ - линейно-линейная функция потерь

2) Логарифмическая функция потерь.
 Пусть в какой-то точке пространства объект $x \in R^d$ задан вероятностью $p(y = +1 | x)$ тогда же объект x будет принадлежать классу $+1$.
 Если в выборке объект x встречается n раз с ответами y_1, \dots, y_n :

$$\arg \min_{b \in R} \frac{1}{n} \sum_{i=1}^n L(y_i, b) \approx p(y = +1 | x)$$
 при стремлении n к бесконечности

$$\arg \min_{b \in R} E[L(y, b) | x] = p(y = +1 | x)$$

С точки зрения алгоритма вероятности того, что в выборке встретится объект x , с классом y равна $b(x, y) = +1 / (1 - b(x, y))$.

$$Q(a, X) = \prod_{i=1}^n b(x_i)^{[y_i = +1]} (1 - b(x_i))^{[y_i = -1]}$$

$$= \sum_{i=1}^n ([y_i = +1] \log b(x_i) + [y_i = -1] \log (1 - b(x_i)))$$

Минимизируя функцию потерь в точке x :

$$E[L(y, b) | x] = E[E[y = +1] \log b - [y = -1] \log (1 - b) | x] =$$

$$= -p(y = +1 | x) \log b - (1 - p(y = +1 | x)) \log (1 - b)$$

Итерационная процедура по b :

$$\frac{\partial}{\partial b} E[L(y, b) | x] = -\frac{p(y = +1 | x)}{b} + \frac{1 - p(y = +1 | x)}{1 - b} = 0$$

Мы будем использовать сигмоидную функцию:

$$p(y = +1 | x) = \frac{1}{1 + \exp(-\langle w, x \rangle)}$$

Вспомогательная из него скалярная производная:

$$\langle w, x \rangle = \log \frac{p(y = +1 | x)}{p(y = -1 | x)}$$

2) Метод опорных векторов.
 Пусть задан некоторый классификатор $a(x) = \text{sign}(\langle w, x \rangle + b)$, если ординировать упомянутые параметры w и b на одну и ту же нормированную константу то классификатор не изменится:

$$\min_{x \in X} |\langle w, x \rangle + b| = 1$$

Расстояние от произвольной точки $x_0 \in R^d$ до гиперплоскости, определенной данными классификатором, равно

$$\min_{x \in X} \frac{| \langle w, x \rangle + b |}{\|w\|} = \frac{1}{\|w\|} \min_{x \in X} | \langle w, x \rangle + b | = \frac{1}{\|w\|}$$

$$\begin{cases} \frac{1}{2} \|W\|^2 + C \sum_{i=1}^{\ell} \xi_i \rightarrow \min_{W, \xi, \varepsilon} \\ y_i (K(W, x_i) + b) \geq 1 - \xi_i, \quad i = 1, \dots, \ell \\ \xi_i \geq 0, \quad i = 1, \dots, \ell \end{cases}$$
$$\begin{cases} \xi_i \geq 1 - y_i (\langle w, x_i \rangle + b) \\ \xi_i \geq 0 \end{cases}$$
$$c_i = \max(0, 1 - \frac{y_i}{(\langle w, x_i \rangle + b)})$$
$$\frac{1}{2} \|w\|^2 + C \sum_{i=1}^L \max(0, 1 - y_i (\langle w, x_i \rangle + b)) \rightarrow \min_{w, b}$$

Тема: Многоклассовое классификация и категориальные признаки

В данном разделе будем считать, что каждый объект относится ко одному из K классов.

$$Y = \{1, \dots, K\}$$

Оценим K линейных классификаторов $v_i(x)$
классов $1, \dots, K$ соответственно.
$$v_i(x) = \langle w_i, x \rangle + w_{i0}$$

Классификатор с напаром K будет обучать по выборке $(x_i, 2[y_i - K] - 1)_{i=1}^n$

$$a(x) = \arg \max_{k \in \{1, \dots, K\}} b_k(x)$$
$$b_k(x) = \text{sign}(\langle w_k, x \rangle + w_{0k})$$

4. Трансформации $a_{ij}(x)$ будем настраивать по подмножеству $X_{ij} \subset X$, содержащему только объекты массов i и j .

$$\text{SoftMax}(z_1, \dots, z_K) = \left(\frac{\exp(z_1)}{\sum_{k=1}^K \exp(z_k)}, \dots, \frac{\exp(z_K)}{\sum_{k=1}^K \exp(z_k)} \right)$$

$$p(y=k|x, \omega) = \frac{\exp(\langle \omega_k, x \rangle + \omega_{0k})}{\sum_{j=1}^K \exp(\langle \omega_j, x \rangle + \omega_{0j})}$$
$$a(x) = \arg \max_{K \in \{1, \dots, K\}} \langle w_K, x \rangle$$
$$\max_k \{ \langle w_k, x \rangle + 1 - [x = y(x)] \} - \langle w_{y(x)}, x \rangle$$
$$\rho = \frac{1}{\|W\|^2} = \frac{1}{\sum_{k=1}^K \sum_{j=1}^J w_{kj}^2}$$
$$\frac{1}{2} \|W\|^2 \rightarrow \min_W$$

$$\frac{1}{2} \|w\|^2 \rightarrow \min_w$$

$$\int \frac{1}{2} \|W\|^2 + C \sum_{i=1}^L \varepsilon_i \rightarrow \min_{W, \varepsilon}$$

$$\langle w_i, x_i \rangle + [y_i = 1] - \langle w_i, x_i \rangle \geq 1 - \epsilon, i = 1, \dots, \ell$$

$$b_i \geq 0, i = 1, \dots, \ell.$$

Две узкие коррелируемые метры классифицируются в зависимости от их взаимного расположения относительно заданной обучающей выборки X на две части X_1 и X_2 . На первой части обучения X_1 и на второй части X_2 классифицируются $\varphi_1(x), \dots, \varphi_n(x)$.

$$X'_{ik} = b_k(x_i), \quad x_i \in X_2$$

Существуют педагоги, которые пытаются вводить
двойку в оценки, используя в основном метод
классового различия, и при этом не делают
примечаний, отговариваясь тем, что классы
как метод не имеют цели.

$V = 115 - VT$

$$Y = U \Sigma V^T$$

Возникли через V_n матрицу составленную из тех M столбцов матрицы V , которые соответствуют ненулевым симметричным элементам строки V_n с ее помощью матрицу V

$V \quad V_n \quad V_n^T \quad V_n V_n^T$

$$Y V_M = Y' \in \mathbb{R}^{l \times M}$$

Впамятении нашей ошибки будет
Халимиево расстояние между землей и небом
то есть массовый факт принадлежности
который указан неверно.

$$\text{hamming}(a, X) = \frac{1}{L} \sum_{i=1}^L |V_i \setminus Z_i| + |Z_i \setminus V_i|$$

Стандартные метрики качества классификации можно считать на `multilabel` - задачу так же как и на `binary` с пересекющимися классами - через микро- или макро-уровни. Это и скажется в итоге потерю к бонусным метрикам.

$$\text{accuracy}(a, X) = \frac{1}{L} \sum_{i=1}^L |V_i \cap Z_i|$$

$$\text{precision}(a, X) = \frac{1}{L} \sum_{i=1}^L \frac{|V_i \cap Z_i|}{|Z_i|}$$

$$\text{recall}(a, X) = \frac{1}{L} \sum_{i=1}^L \frac{|V_i \cap Z_i|}{|V_i|}$$

③ Категориальные признаки

Простейший способ - создать n индикаторов, каждый из которых будет отвечать за одно из возможных значений признака. Вывод: $g_1(x), \dots, g_n(x)$ которые определяются как

$$g_i(x) = [f(x) = u_i]$$

Определим наш способ кодирования. Введем для каждого значения u категориального признака $(k+1)$ вектор:

$$\text{counts}(u, X) = \sum_{(x,y) \in X} [f(x) = u]$$

$$\text{successes}_k(u, X) = \sum_{(x,y) \in X} [f(x) = u] [y = k]$$

После того как данные значения порешены значениями n категориальных признаков $f(x)$ на k множествах $g_1(x), \dots, g_n(x)$

$$g_k(x, X) = \frac{\text{successes}(f(x), X) + c_k}{\text{counts}(f(x), X) + \sum_{m=1}^K c_m}, \quad k = 1, \dots, K$$

При использовании счетчиков передо используется `add` трюки:

1. В признаках можно добавлять не только `g_k(x)`, но и значение `counts(f(x), X)` и `successes_k(f(x), X)`

2. Можно сгенерировать новые категориальные признаки, т.е. для каждой пары категориальных признаков $f_1(x)$ и $f_2(x)$ создать новый признак $f_{12}(x) = (f_1(x), f_2(x))$

3. Если у категориальных признаков много возможных значений, то значение статистик `counts(u, X)` и `successes(u, X)` имеют порядок `size` кол-ва памяти.

4. Можно вычислять несколько счетчиков для разных значений параметров c_1, \dots, c_K .

5. Можно все разные значения категориальных признаков объединить в одно, поскольку скорее всего для разных значений не найдется качественно лучше статистику `successes_k` и `counts`.